

1

Seleção e Curadoria do Corpus



SCIENCE
PANEL FOR
THE AMAZON

Science Panel for the Amazon

Fonte única de autoridade:
Amazon Assessment Report 2021
(Science Panel for the Amazon)



38 documentos
científicos



1.337 páginas




Alta densidade
técnica e científica

2

Extração e Processamento de Layout

Extração com
Unstructured (hi_res)



Recursos aplicados



Modelos de Visão
Computacional



Detecção nativa
de tabelas (HTML)



Preservação de ordem
lógica de leitura

3

Limpeza e Fragmentação

Limpeza via Regex

- × Remoção de cabeçalhos
- × Remoção de rodapés
- × Remoção de índices
- × Remoção de ruídos visuais

Chunking por Título



Segmentação semântica
respeitando quebras
de subseções

Tamanho dos chunks

500 – 1.000
caracteres

ARTEFATOS
GERADOS



Corpus bruto
(38 documentos)
PDFs originais do SPA



Arquivos JSON
estruturados
38 arquivos (Elementos
e Metadados)



6.899 chunks limpos
e segmentados
Blocos de 500-1.000 caracteres

4

Enriquecimento com Metadados

Injeção de Metadados



Nome de arquivo



Capítulo



Seção / Subseção



Página física original



ID do chunk (único)

Garante rastreabilidade total e validação
instantânea da fonte científica

5


Indexação Vetorial

Geração de Embeddings



[0.12, -0.85, 0.31, ..., 0.64]

Indexação com ChromaDB



Base vetorial persistente e escalável



Base Vetorial do Corpus

6

Criação do SPAmazon-QA

Geração de Perguntas e Respostas
por Modelos de Fronteira
(GPT, Gemini, Claude)



Respostas de Referência (com validação humana)



Respostas fundamentadas
e verificadas no corpus

Repositório Curado
130

pares de perguntas e respostas

ARTEFATOS
GERADOS



Chunks com
metadados
Rastreáveis por arquivo,
capítulo, seção e página



Índice vetorial (ChromaDB)
Base para busca semântica
e recuperação (RAG)



Repositório Curado
130 pares QA
Para avaliação e auditoria
de modelos