

SPAmazon-QA: Um Repositório de Dados Estruturado e Curado para Avaliação de LLMs sobre a Amazônia

**Ana C. G. Torres¹, Lucas Louzada², Marcos H. Costa²,
Julio C. S. Reis¹, Daniel L. Fernandes¹**

¹Departamento de Informática – Universidade Federal de Viçosa – Brasil

²Departamento de Engenharia Agrícola – Universidade Federal de Viçosa – Brasil

{ana.torres, lucas.louzada, mhcosta, jreis, daniel.louzada}@ufv.br

Abstract. *This work presents the SPAmazon-QA, a curated repository based on reports from the Science Panel for the Amazon (SPA), designed for the development, calibration, and evaluation of AI systems in the Amazonian socio-environmental domain. The repository contains a structured and processed corpus of 38 SPA chapters, suitable for semantic retrieval and RAG architectures, as well as a curated set of 130 specialized question-and-answer pairs. It also includes answers generated by different large-scale language models (LLMs) and their respective evaluations, enabling comparative performance analyses. SPAmazon-QA is expected to serve as a baseline for auditing and developing reliable RAG systems aimed at the sustainable development of the Amazon.*

Resumo. *Este trabalho apresenta o SPAmazon-QA, um repositório curado fundamentado nos relatórios do Science Panel for the Amazon (SPA), voltado ao desenvolvimento, calibração e avaliação de sistemas de IA no domínio socioambiental amazônico. O repositório reúne um corpus estruturado e tratado de 38 capítulos do SPA, adequado para recuperação semântica e arquiteturas RAG, além de um conjunto curado de 130 pares de perguntas e respostas especializadas. O repositório também inclui respostas geradas por diferentes grandes modelos de linguagem (LLMs) e suas respectivas avaliações, permitindo análises comparativas de desempenho. Espera-se que o SPAmazon-QA contribua como linha de base para auditoria e desenvolvimento de sistemas RAG confiáveis voltados ao desenvolvimento sustentável da Amazônia.*

1. Introdução

O desenvolvimento sustentável e a preservação da Amazônia representam desafios globais inadiáveis [Lovejoy and Nobre 2018]. Esta floresta, maior bioma tropical do planeta, exerce um papel essencial na regulação climática global, na manutenção do ciclo hidrológico e na preservação da biodiversidade [Marengo et al. 2021]. No entanto, a região se aproxima de um ponto de não retorno, isto é, limiar crítico a partir do qual a floresta pode perder sua capacidade de regeneração e sofrer mudanças ecológicas irreversíveis, impulsionado pela sinergia entre o desmatamento, a degradação florestal e as mudanças climáticas [Assis et al. 2019, MapBiomas 2024]. Diante deste cenário de crise ambiental, decisões críticas tornam-se necessárias para a formulação de políticas públicas e estratégias de conservação, sustentadas por evidências científicas e dados confiáveis.

Para fornecer esse embasamento, a comunidade científica internacional organizou diversas iniciativas inéditas, destacando-se o Painel Científico para a Amazônia (*Science Panel for the Amazon* - SPA¹), composto por mais de 200 cientistas e pesquisadores dos países amazônicos e parceiros internacionais, responsável por sintetizar o conhecimento acumulado sobre a região amazônica em centenas de páginas de relatórios técnicos, de natureza interdisciplinar, elaborados com base em consenso científico [Nobre et al. 2021]. O material produzido aborda aspectos relacionados ao sistema terrestre, às transformações socioecológicas e aos caminhos sustentáveis para a Amazônia. Contudo, o volume massivo de dados dessa literatura técnico-científica cria uma barreira ao acesso e à compreensão do conhecimento por formuladores de políticas públicas, pesquisadores, educadores e pela sociedade em geral.

Diante deste cenário, os Grandes Modelos de Linguagem (*Large Language Models* - LLMs) vêm sendo investigados como ferramentas promissoras para apoiar a síntese, a recuperação e a democratização de informações. Por meio de interfaces conversacionais, esses modelos favorecem o acesso de diferentes públicos a conteúdos especializados [Zhao et al. 2023]. Entretanto, independente de sua natureza, sejam modelos comerciais de ponta (como *Gemini* e *Claude*) ou modelos de código aberto (como *Llama* e *Mistral*), essas tecnologias enfrentam desafios de confiabilidade. Treinados em grandes conjuntos de dados heterogêneos da Web, esses modelos frequentemente combinam conteúdos com limitada curadoria especializada, o que introduz inconsistências, vieses geográficos e as chamadas “alucinações”, respostas plausíveis, mas factualmente incorretas [Penedo et al. 2023, Alber et al. 2025, Huang et al. 2025].

Para mitigar esses problemas de confiabilidade na recuperação de informações científicas, a arquitetura de *Retrieval-Augmented Generation* (RAG) tem se destacado na literatura como um mecanismo para fundamentar respostas geradas por LLMs em fontes seguras e qualificadas [Lewis et al. 2020, Gao et al. 2023]. Contudo, a avaliação da eficácia desses sistemas depende da existência de bases de dados com curadoria especializada para calibração e validação das respostas geradas. A carência de recursos voltados ao contexto amazônico compromete tanto a avaliação da precisão dos modelos quanto a identificação de erros de conteúdo, principalmente por usuários não especialistas [Nobre et al. 2021, Blasi et al. 2022].

Nesse contexto, este trabalho apresenta o *SPAmazon-QA*², um repositório estruturado e curado de dados para apoiar o desenvolvimento, a calibração e a avaliação de sistemas de Inteligência Artificial (IA) aplicado ao domínio socioambiental amazônico. O repositório é composto por: (i) um *corpus* extraído, estruturado e tratado a partir de 38 capítulos do SPA, voltado à recuperação semântica e fundamentação de arquiteturas RAG; e (ii) um conjunto curado contendo 130 pares de perguntas e respostas especializadas.

Diferente de repositórios relacionados, que são puramente sintéticos, o *SPAmazon-QA* fornece um referencial para avaliar a precisão factual de modelos de linguagem, seja em leitura compreensiva, ajuste fino de domínio ou na geração de respostas. Espera-se que este recurso contribua para a rastreabilidade das informações científicas, apoiando aplicações voltadas ao desenvolvimento sustentável da Amazônia.

¹Disponível em: <https://www.sp-amazon.org/publications/>

²Publicamente disponível em: <https://github.com/AnaClaraGuerra22/SPAmazon-QA>

2. Trabalhos Relacionados

Trabalhos recentes têm explorado a construção de bases de dados, *corpora* e conjuntos de avaliação estruturados para a adaptação e a validação de LLMs em domínios científicos, com foco na curadoria de dados para mitigação de alucinações [Ji et al. 2023, Huang et al. 2025]. Nesse contexto, destaca-se a criação de repositórios de perguntas e respostas (*Question and Answer - QA*) voltados a domínios específicos, como o conjunto de dados *PubMedQA* [Jin et al. 2019] no domínio biomédico, o *FinQA* [Chen et al. 2021] no setor financeiro e o *QASports* [Jardim et al. 2023] no contexto esportivo. Essa tendência tem impulsionado o desenvolvimento de *corpora* e *benchmarks* especializados para ampliar a capacidade dos modelos em tarefas de domínio específico [Zhao et al. 2023]. Contudo, aplicações voltadas ao sistema socioecológico amazônico permanecem escassas na literatura.

No setor agrícola, destaca-se o *AgriGPT* [Yang et al. 2025], projetado para fornecer consultoria técnica e suporte à agricultura inteligente por meio da recuperação de conhecimento especializado. O modelo foi desenvolvido com base no *Agri-342K Corpus*, um conjunto de dados massivo com mais de 340 mil documentos técnicos. Metodologicamente, a construção dessa base estruturada permite ao modelo superar lacunas de terminologia técnica e realizar inferências precisas no domínio das ciências agrárias. Embora o *AgriGPT* demonstre como a curadoria de *corpora* de domínio eleva o desempenho prático da IA, seu escopo é voltado à produção agrícola global, distanciando-se de desafios atrelados à conservação de biomas naturais.

No domínio das ciências climáticas e geociências, a literatura tem avançado em diferentes níveis de especialização, abrangendo desde modelos fundacionais amplos, como o *JiuZhou* [Chen et al. 2025b], projetado para a compreensão estrutural de dados geocientíficos, até ferramentas ajustadas para nichos, como o *ClimateChat* [Chen et al. 2025a], um LLM especializado em mudanças climáticas. Para a adaptação do *ClimateChat*, os autores construíram o *ClimateChat-Corpus*, um conjunto de dados elaborado a partir de três estratégias complementares: (i) geração automática de pares de perguntas e respostas (*self-QA*) com auxílio de LLMs, a partir de relatórios do Painel Intergovernamental sobre Mudanças Climáticas e artigos científicos; (ii) coleta e filtragem de conteúdos especializados via *web scraping* em fóruns técnicos; e (iii) geração sintética de instruções por meio de técnicas de *self-instruct* e aprendizado com poucos exemplos (*few-shot learning*). Os resultados demonstraram que a utilização de *corpora* especializados contribui para melhorar o desempenho dos modelos em tarefas relacionadas às ciências da Terra.

Apesar da relevância metodológica dessas iniciativas, observa-se que ecossistemas como *AgriGPT*, *JiuZhou* e *ClimateChat* operam predominantemente em contextos globais ou em aplicações gerais de geociências. Como consequência, esses sistemas não contemplam adequadamente as particularidades socioambientais e os desafios de conservação associados à Amazônia. Além dessa lacuna temática, a literatura destaca que a avaliação de arquiteturas RAG em domínios críticos requer referenciais confiáveis de validação [Lewis et al. 2020].

Estudos recentes indicam que a dependência exclusiva de instâncias sintéticas é insuficiente, reforçando a necessidade de *benchmarks* construídos com curadoria humana [Gao et al. 2023]. É exatamente na interseção dessas duas carências, a ausência de dados focados na região amazônica e a necessidade de avaliações auditadas, que

o *SPAmazon-QA* se insere. O presente trabalho busca preencher essas lacunas ao disponibilizar um repositório estruturado composto por um *corpus* especializado e um conjunto curado para avaliação de LLMs no contexto da Amazônia.

3. Metodologia para Construção do *SPAmazon-QA*

Esta seção descreve a metodologia adotada para a construção do *SPAmazon-QA*. A Figura 1 ilustra o fluxo geral, estruturado em um *pipeline* de seis etapas principais: (1) Seleção e Curadoria do *Corpus*; (2) Extração e Processamento de *Layout*; (3) Limpeza e Fragmentação Textual; (4) Enriquecimento com Metadados; (5) Indexação Vetorial; e (6) Criação do Repositório. Essas etapas estão detalhadas nas seções a seguir.

3.1. Seleção e Estruturação do *Corpus*

O primeiro componente do *SPAmazon-QA* consiste em uma base de conhecimento estruturada destinada à fundamentação de sistemas RAG. Conforme ilustrado na Etapa 1 da Figura 1, o *corpus* foi construído exclusivamente a partir do *Amazon Assessment Report* 2021, publicado pelo SPA [Nobre et al. 2021]. Este conjunto de documentos compreende 38 relatórios em formato PDF, redigidos em língua inglesa, totalizando 1.337 páginas de conteúdo técnico-científico. A extração e o processamento desses documentos resultaram na geração de 6.899 fragmentos textuais (*chunks*) limpos, segmentados semanticamente e enriquecidos com metadados.

A relevância deste conjunto reside na consolidação de uma das principais fontes científicas sobre a Amazônia em um recurso computacional estruturado para aplicações

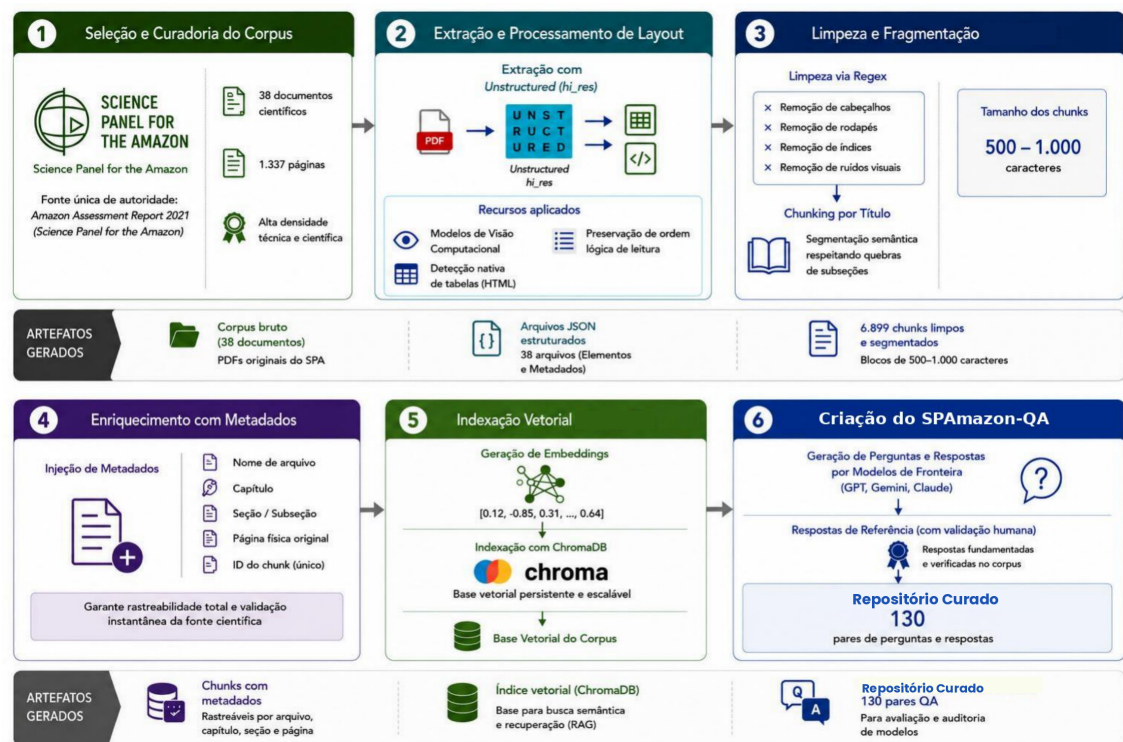


Figura 1. Fluxo metodológico adotado para a construção do repositório *SPAmazon-QA*.

de recuperação de informação, sistemas de QA e modelos baseados em LLMs. O processo de extração e organização dos documentos permitiu transformar um grande volume de conteúdos técnicos desestruturados em uma base especializada para recuperação de informação no domínio socioambiental amazônico, reduzindo a dependência de conteúdos genéricos provenientes da Web.

Relatórios científicos de grande porte, com média de aproximadamente 35 ± 13 páginas por documento, como os do SPA, apresentam desafios para extração automática de texto devido à presença de diagramações em múltiplas colunas, tabelas e elementos gráficos, que frequentemente comprometem a qualidade de ferramentas convencionais de reconhecimento óptico de caracteres (*Optical Character Recognition* - OCR) [Cui et al. 2021]. Para preservar a hierarquia estrutural desses documentos, a extração do texto foi realizada (Etapa 2) com a biblioteca *Unstructured*³, utilizando a estratégia *hi-res*, que emprega modelos de Visão Computacional para inferência da geometria da página e detecção nativa de tabelas em HTML. Essa abordagem permitiu a obtenção de elementos textuais estruturados a partir dos documentos originais.

Os elementos textuais extraídos foram então submetidos a um *pipeline* de pré-processamento voltado à preparação do *corpus* (Etapas 3 e 4) para posterior indexação vetorial no *ChromaDB*⁴ (Etapa 5):

- **Limpeza via regex:** Remoção de ruídos visuais, cabeçalhos, rodapés, parágrafos institucionais e índices extraídos durante o processamento dos documentos;
- **Chunking por título:** Segmentação do texto em blocos semânticos de 500 a 1.000 caracteres; intervalo padrão definido para equilibrar a especificidade da busca vetorial com a preservação do contexto semântico. O processo respeita a estrutura hierárquica de capítulos e subseções para evitar a fragmentação de ideias centrais;
- **Estruturação de metadados:** Enriquecimento de cada *chunk* com metadados estruturais, incluindo nome do arquivo, capítulo, seção, subseção e página original.

A estruturação dos metadados assegura rastreabilidade documental e possibilita a validação direta das fontes recuperadas em sistemas RAG [Harris et al. 2024]. Em seguida, os *chunks* foram convertidos em representações vetoriais por meio do modelo de *embeddings* *all-mpnet-base-v2*⁵, disponibilizado pela biblioteca *Sentence-Transformers*, amplamente utilizado em tarefas de busca semântica em língua inglesa devido ao seu desempenho na captura de similaridade contextual. Os vetores gerados foram então indexados no banco de dados vetorial *ChromaDB*, viabilizando a recuperação semântica de conteúdos em aplicações baseadas em LLMs (Etapa 5).

3.2. Construção do Conjunto Curado

O *SPAmazon-QA* também incorpora um conjunto curado, projetado para mensurar a precisão factual de LLMs e validar respostas no contexto amazônico. Enquanto o *corpus* especializado fornece a infraestrutura de dados para recuperação semântica em sistemas RAG, esse referencial curado estabelece a base para auditoria e avaliação de modelos.

³Disponível em: <https://github.com/Unstructured-IO/unstructured>

⁴Disponível em: <https://github.com/chroma-core/chroma>

⁵Disponível em: <https://huggingface.co/sentence-transformers/all-mpnet-base-v2>

O conjunto de avaliação foi construído a partir do processamento integral dos documentos originais, em que cada um dos 38 relatórios foi submetido diretamente a três LLMs distintos (*Claude 3.5 Sonnet*, *Gemini 2.5 Pro* e *GPT-4o*).

A seleção desses modelos generativos fundamentou-se no seu desempenho em *benchmarks* de raciocínio e compreensão textual, buscando assegurar que a base inicial de QA fosse produzida por sistemas com elevada capacidade de síntese e extração de conteúdo. Além disso, a utilização de modelos pertencentes a diferentes famílias (*Anthropic*, *Google* e *OpenAI*) favorece a diversidade do conjunto inicial de questões ao incorporar distintas estratégias de geração textual, reduzindo possíveis vieses associados a uma única arquitetura [Zheng et al. 2023].

A geração sintética foi conduzida por meio de coleta manual via interface *web* e de técnicas de engenharia de comandos. O *prompt* adotou a estratégia de definição de *persona* (*role-based prompting*) [Amatriain 2024], instruindo os modelos a atuarem como especialistas em sustentabilidade amazônica. Foram estabelecidas diretrizes para assegurar a qualidade e a diversidade do conjunto de dados, incluindo: (i) a formulação de, no mínimo, um par de QA para cada intervalo de três páginas processadas; (ii) a utilização do inglês como idioma padrão; (iii) a construção de perguntas autossuficientes, sem menções diretas ao documento de origem (por exemplo, “conforme o texto” ou “segundo o autor”); e (iv) a atribuição obrigatória do nível de dificuldade de QA (fácil, intermediário ou difícil) pelo próprio modelo generativo.

As instâncias geradas sob essas restrições totalizaram 1.246 pares de QA, organizados em arquivos de texto independentes por modelo generativo. A partir desse volume bruto, foram amostrados aleatoriamente 130 pares para compor o conjunto curado final de avaliação. A definição desse quantitativo de amostragem (cerca de $\approx 10\%$ do total) foi necessária para viabilizar o processo de revisão manual e curadoria especializada, o qual foi realizado em seguida pelos autores deste trabalho. Essa etapa consistiu em uma verificação de consistência voltada à comparação entre os gabaritos e os trechos correspondentes dos relatórios do SPA.

O procedimento descrito não teve como objetivo realizar validação técnico-científica do conteúdo extraído do SPA, mas sim revisar a coerência textual das instâncias, removendo redundâncias, falhas estruturais e alucinações identificáveis. Esse processo de refinamento atuou como um filtro sobre os ruídos da geração automatizada, resultando em um conjunto curado para avaliação de LLMs.

Após o processo de curadoria, o conjunto final consolidou 130 pares de QA de diferentes níveis de dificuldade e modelos. A Tabela 1 apresenta a composição final das instâncias segundo essas categorias. Nota-se que *Claude 3.5 Sonnet* gerou mais questões difíceis enquanto o *GPT-4o* concentrou-se mais nas fáceis e intermediárias.

Tabela 1. Distribuição dos pares de QA do SPAmazon-QA segundo o LLM e o nível de dificuldade atribuído.

LLM	Fácil	Intermediário	Difícil	Total
<i>Claude 3.5 Sonnet</i>	2	15	32	49
<i>Gemini 2.5 Pro</i>	3	23	17	43
<i>GPT-4o</i>	9	25	4	38
Total	14	63	53	130

Tabela 2. Estatísticas descritivas da estrutura textual das perguntas do SPAmazon-QA. M: Média; DP: Desvio Padrão; Caract.: Caracteres; VU: Vocabulário Único; DL: Diversidade Lexical (%).

LLM	Palavras (M $\pm$ DP)	Caract. (M $\pm$ DP)	VU	DL (%)
<i>Claude 3.5 Sonnet</i>	17,7 $\pm$ 4,8	114,9 $\pm$ 33,3	332	38,3
<i>Gemini 2.5 Pro</i>	18,1 $\pm$ 3,4	117,6 $\pm$ 24,7	369	47,4
<i>GPT-4o</i>	14,8 $\pm$ 3,0	103,8 $\pm$ 19,5	318	56,7

Para caracterizar o perfil textual das instâncias geradas, foram calculadas estatísticas descritivas relacionadas à estrutura das perguntas, apresentadas na Tabela 2. A análise evidencia variações nos padrões de formulação entre os modelos utilizados. O *Gemini 2.5 Pro*, por exemplo, produziu perguntas com maior extensão média (18,1 $\pm$ 3,4 palavras) e maior vocabulário único (VU) (369 palavras). Em contraste, o *GPT-4o* apresentou perguntas mais concisas (14,8 $\pm$ 3,0 palavras), mas com a maior diversidade lexical (DL) (56,7%), indicando menor repetição vocabular entre as instâncias geradas.

O *Claude 3.5 Sonnet* manteve uma extensão média de perguntas próxima à do *Gemini 2.5 Pro* (17,7 $\pm$ 4,8 palavras), porém com a menor DL entre os modelos avaliados (38,3%). No panorama geral, o conjunto apresenta média $\approx$ 17 palavras por enunciado, sugerindo a formulação de perguntas relativamente detalhadas e contextualizadas.

O processo de construção do conjunto curado combinou geração sintética assistida por LLMs com curadoria humana, buscando assegurar diversidade temática, rastreabilidade documental e alinhamento técnico com os relatórios do SPA. Como resultado, o repositório produzido configura-se como uma ferramenta confiável não apenas para auditoria de novos LLMs, mas também para avaliação de mecanismos de recuperação em arquiteturas RAG aplicadas ao contexto da sustentabilidade amazônica.

3.3. Estrutura e Disponibilização do Repositório

Para facilitar a reutilização do SPAmazon-QA em pesquisas e aplicações envolvendo LLMs, recuperação de informação e sistemas de QA, tanto o *corpus* quanto o conjunto curado foram disponibilizados publicamente no repositório do projeto². Os dados estão organizados em formato hierárquico *JavaScript Object Notation* (JSON), permitindo representação estruturada de perguntas, respostas, metadados e avaliações produzidas pelos diferentes LLMs testados.

O principal diferencial do SPAmazon-QA reside no fato de que o repositório ultrapassa a simples disponibilização de pares de QA, incorporando inferências produzidas por diferentes modelos sob critérios padronizados de avaliação. Para ampliar a diversidade de cenários avaliados, foram utilizados o modelo generalista *Meta-Llama-3-8B*⁶, pertencente à família *Llama 3.3* [Grattafiori et al. 2024], e o modelo especializado *ClimateChat*⁷ [Chen et al. 2025a], ambos avaliados em configuração *zero-shot*, sem utilização de mecanismos externos de recuperação de contexto.

Paralelamente, para a avaliação dos modelos generativos (*GPT-4o*, *Claude 3.5*

⁶Disponível em: <https://huggingface.co/meta-llama/Meta-Llama-3-8B>

⁷Empregando o *checkpoint* *ClimateChat.i1-Q4_K_M.gguf*, disponível em: https://huggingface.co/mradermacher/ClimateChat-i1-GGUF/blob/main/ClimateChat.i1-Q4_K_M.gguf

Sonnet e *Gemini 2.5 Pro*), utilizou-se um protocolo manual de inferência controlada, baseado em comandos padronizados. Esses comandos restringiam as respostas geradas a, no máximo, três parágrafos e vedavam o uso de preâmbulos discursivos genéricos, buscando favorecer respostas mais objetivas e tecnicamente fundamentadas.

Para mitigar o viés de autoria, isto é, o favorecimento potencial de um modelo ao responder perguntas originalmente geradas por ele próprio, foi implementado um protocolo de teste cego cruzado. Nesse procedimento, o modelo responsável pela geração inicial de determinada pergunta na Etapa 6 foi impedido de responder à sua própria instância durante a fase de avaliação.

Com a coleta dessas múltiplas inferências, cada objeto do repositório passou a obedecer à seguinte hierarquia de atributos:

- **metadados_pergunta:** Contém o tipo de questão (direta/indireta), a classificação de dificuldade, o capítulo alvo do SPA e o índice de subjetividade, calculado via *Text-Blob* [Loria et al. 2021], biblioteca de processamento de texto utilizada para quantificar a polaridade e a neutralidade acadêmica das sentenças geradas;
- **conjunto_curado:** A resposta esperada, abrigando a pergunta original e a resposta desejada formulada estritamente com base nos relatórios do SPA;
- **avaliacoes_modelos:** Um vetor aninhado contendo o histórico de respostas para aquela mesma pergunta por parte dos diferentes modelos concorrentes. Para cada arquitetura, forneceu-se a resposta gerada, a nota atribuída pela avaliação automatizada em escala Likert e a justificativa técnica dessa penalização.

Para escalar a avaliação automatizada das respostas geradas em relação ao gabarito de referência, o conjunto de dados adota o paradigma Juiz LLM (*LLM-as-a-Judge*) [Zheng et al. 2023], utilizando o modelo *Llama-3.3-70B-Versatile*⁸, integrado via infraestrutura *cloud*, como avaliador sintético. O processo de avaliação emprega uma escala *Likert* de cinco pontos estruturada da seguinte forma: Nota 1 (Incorreta), atribuída a respostas erradas ou irrelevantes; Nota 2 (Fracas), para respostas que abordam parcialmente o tema, mas apresentam erros conceituais ou omissões centrais; Nota 3 (Parcial), destinada a respostas incompletas ou superficiais; Nota 4 (Boa), para respostas corretas com pequenas falhas ou omissões secundárias; e Nota 5 (Excelente), indicando respostas detalhadas, consistentes e alinhadas aos relatórios do SPA.

A Tabela 3 apresenta a média global das notas atribuídas aos modelos avaliados no conjunto curado. Os resultados revelam *insights* relevantes sobre o desempenho de modelos de propósito geral no contexto amazônico. Observa-se que modelos comerciais, como o *Claude 3.5 Sonnet* e o *Gemini 2.5 Pro*, alcançam as maiores médias de avaliação. Contudo, ambos também apresentam os maiores desvios padrão, indicando uma maior variabilidade na qualidade das respostas geradas. Esse comportamento sugere que, embora tais modelos sejam capazes de produzir respostas precisas e detalhadas em determinados cenários, eles também são suscetíveis a falhas de fundamentação conceitual, ocasionando uma distribuição polarizada entre avaliações elevadas e notas baixas (1 e 2).

O desafio torna-se ainda mais evidente em modelos generalistas não espe-

⁸Disponível em: <https://console.groq.com/docs/model/llama-3.3-70b-versatile>

Tabela 3. Resultados médios da avaliação conduzida pelo Juiz LLM utilizando escala *Likert* de 1 a 5.

LLM Avaliado	Média Likert	Desvio Padrão	Instâncias Avaliadas
<i>Claude 3.5 Sonnet</i>	4,3	1,4	81
<i>ClimateChat</i>	3,5	1,0	130
<i>Gemini 2.5 Pro</i>	4,1	1,3	87
<i>GPT-4o</i>	3,9	1,1	92
<i>Meta-Llama-3-8B</i>	1,7	1,1	130

cializados, como o *Meta-Llama-3-8B*, que apresentou a menor média geral e forte concentração de avaliações críticas. Mesmo o *ClimateChat*, apesar de possuir especialização prévia em ciências climáticas, obteve desempenho moderado quando submetido ao rigor técnico-científico dos relatórios do SPA. Essa variação entre os modelos avaliados, aliada à dificuldade em manter alinhamento consistente com o conteúdo de referência, evidencia a complexidade temática do *corpus* e reforça a utilidade prática do *SPAmazon-QA* como um conjunto curado para validação de LLMs em aplicações voltadas ao contexto amazônico.

Dessa forma, a estrutura proposta para o *SPAmazon-QA* não apenas documenta o desempenho atual de LLMs nesse domínio, mas também disponibiliza uma infraestrutura auditável que permite a pesquisadores e desenvolvedores calibrar novos modelos, investigar limitações de métricas automáticas de avaliação e aprimorar a confiabilidade de sistemas inteligentes aplicados à sustentabilidade amazônica.

3.4. Ambiente Computacional

Os experimentos foram realizados em ambiente *Jupyter Notebook* com *Python 3.13*, em um *laptop* com processador AMD Ryzen 7 5800H, 8 GB de RAM e GPU NVIDIA GeForce GTX 1650 (4 GB VRAM), executando *Windows 11*. As rotinas de extração e indexação vetorial foram executadas majoritariamente em CPU, com paralelização e controle de *threads* para otimização do desempenho.

4. Potencial de Utilização do Repositório

Nesta seção, apresentam-se algumas direções de pesquisa que podem se beneficiar do repositório disponibilizado.

Otimização de arquiteturas RAG e recuperação de informação. O conjunto de dados estruturado serve como um ambiente de testes para o aprimoramento de sistemas de recuperação de informação semântica. Pesquisadores podem explorar o repositório para testar novos algoritmos de geração de *embeddings*, avaliar o impacto de diferentes estratégias de particionamento (*chunking*) e comparar a eficácia de abordagens de busca densa, em bancos vetoriais, contra buscas esparsas tradicionais ou híbridas na recuperação de literatura científica.

Ajuste fino e adaptação de modelos. Assim como iniciativas globais utilizaram conjuntos de dados específicos para treinar modelos focados no clima [Chen et al. 2025a], os dados do *SPAmazon-QA* podem ser empregados no *instruction tuning* para a criação de LLMs especialistas em ciências ambientais. A base em formato JSON permite treinar arquiteturas para que assimilem nativamente a terminologia técnica e o rigor acadêmico inerentes ao bioma amazônico, superando as limitações dos modelos de uso geral.

Pesquisa em avaliadores artificiais e metodologias de avaliação. O conjunto de dados do presente trabalho disponibiliza as perguntas e os gabaritos de referência, assim como um vasto histórico de inferências de seis modelos distintos. Esses dados incluem notas em escala Likert e justificativas técnicas detalhadas geradas por avaliadores sintéticos. Dessa forma, o repositório torna-se um campo fértil para pesquisas em meta-avaliação, área da computação dedicada a investigar a confiabilidade e a precisão das próprias métricas e dos modelos usados para avaliar outras IAs. A comunidade pode utilizar essas informações para investigar o grau de alinhamento entre a avaliação automatizada (Juiz LLM) e o rigor científico exigido por especialistas humanos, promovendo o desenvolvimento de *frameworks* de auditoria mais justos e explicáveis.

Avaliação de sistemas de QA tradicionais. Além de arquiteturas generativas, o conjunto curado serve para avaliar o desempenho de modelos de QA tradicionais e de compreensão de leitura. Pesquisadores podem aferir a capacidade de modelos extrativos em localizar e extrair trechos exatos de respostas a partir dos fragmentos do *corpus*, como faz a arquitetura bidirecional BERT [Devlin et al. 2019]. Essa abordagem amplia a utilidade da base, permitindo testes de desempenho em tarefas de extração direta de informação, para além do escopo exclusivo de geração livre de texto.

Sistemas de apoio à decisão para sustentabilidade. O repositório atua como uma ponte entre a literatura científica e a formulação de políticas públicas. Os dados podem ser utilizados para treinar e validar sistemas que democratizem o acesso ao conhecimento do SPA, permitindo que gestores e educadores consultem informações sobre vulnerabilidade do bioma amazônico, assim como os caminhos pela sustentabilidade do mesmo com garantias de rastreabilidade e rigor científico.

5. Conclusão e Trabalhos Futuros

Neste trabalho, foi apresentado o *SPAmazon-QA*, um repositório de dados aberto desenvolvido para aplicações envolvendo LLMs no contexto amazônico. O repositório integra duas frentes complementares: (i) uma base estruturada para arquiteturas RAG, composta por fragmentos textuais extraídos dos relatórios oficiais do SPA; e (ii) um conjunto curado contendo 130 pares de QA destinados à avaliação de modelos de linguagem.

Como diferencial, o repositório incorpora gabaritos de referência, inferências produzidas por diferentes modelos generativos e auditorias semânticas realizadas via Juiz LLM, promovendo maior transparência analítica na investigação de alucinações algorítmicas em domínios especializados. Espera-se que o acesso público a essa infraestrutura contribua para pesquisas em recuperação semântica, ajuste fino de modelos e desenvolvimento de sistemas inteligentes mais confiáveis para aplicações voltadas ao desenvolvimento sustentável da Amazônia.

Apesar das contribuições apresentadas, o trabalho possui limitações relacionadas à escala do conjunto curado, à dependência exclusiva dos relatórios do SPA como fonte de conhecimento e à ausência de especialistas de domínio no processo de curadoria. Como trabalhos futuros, pretende-se expandir o *SPAmazon-QA* para cenários multimodais e para diferentes línguas, além de investigar estratégias de especialização de modelos e arquiteturas híbridas de recuperação semântica. Também se planeja desenvolver um sistema RAG baseado no repositório proposto, utilizando o *SPAmazon-QA* como infraestrutura de recuperação e possível *benchmark* para avaliação das respostas geradas.

Agradecimentos

Este trabalho foi parcialmente financiado pela FAPEMIG.

Uso de Inteligência Artificial

Foi utilizada a ferramenta ChatGPT (*OpenAI*) para revisão gramatical e geração da figura deste trabalho. Os autores revisaram e validaram todo o conteúdo produzido.

Referências

- Alber, D. A. et al. (2025). Medical large language models are vulnerable to data-poisoning attacks. *Nature Medicine*, 31(2):618–626.
- Amatriain, X. (2024). Prompt design and engineering: Introduction and advanced methods. *arXiv preprint arXiv:2401.14423*.
- Assis, L. F. F. G. et al. (2019). Terrabrasilis: A spatial data analytics infrastructure for large-scale thematic mapping. *ISPRS International Journal of Geo-Information*, 8(11):513.
- Blasi, D., Anastasopoulos, A., and Neubig, G. (2022). Systematic inequalities in language technology performance across the world’s languages. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 5486–5505.
- Chen, Z. et al. (2021). Finqa: A dataset of numerical reasoning over financial data. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 3697–3711.
- Chen, Z. et al. (2025a). Climatechat: Designing data and methods for instruction tuning llms to answer climate change queries. In *Proceedings of the 2025 International Conference on Learning Representations (ICLR) Workshop*. International Conference on Learning Representations.
- Chen, Z. et al. (2025b). Jiuzhou: Open foundation language models and effective pre-training framework for geoscience. *International Journal of Digital Earth*, 18(1):2449708.
- Cui, L. et al. (2021). Document ai: Benchmarks, models and applications. *arXiv preprint arXiv:2111.08609*.
- Devlin, J. et al. (2019). Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pages 4171–4186.
- Gao, Y. et al. (2023). Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*, 2(1):32.
- Grattafiori, A. et al. (2024). The llama 3 herd of models. *arXiv preprint arXiv:2407.21783*.
- Harris, N., Butani, A., and Hashmy, S. (2024). Enhancing embedding performance through large language model-based text enrichment and rewriting. *Advances in Artificial Intelligence and Machine Learning Research*, 4(2):2358–2368.

- Huang, L. et al. (2025). A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. *ACM Transactions on Information Systems*, 43(2):1–55.
- Jardim, P. C., Moraes, L. M. P., and Aguiar, C. D. (2023). Qasports: A question answering dataset about sports. In *Dataset Showcase Workshop (DSW)*, pages 1–12. SBC.
- Ji, Z., Lee, et al. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38.
- Jin, Q. et al. (2019). Pubmedqa: A dataset for biomedical research question answering. In *Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP)*, pages 2567–2577.
- Lewis, P. et al. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in Neural Information Processing Systems*, 33:9459–9474.
- Loria, S. et al. (2021). Textblob: simplified text processing-textblob 0.16. 0 documentation. *TextBlob: Simplified Text Processing*.
- Lovejoy, T. E. and Nobre, C. (2018). Amazon tipping point. *Science advances*, 4(2):eaat2340.
- MapBiomass (2024). Rad2023: Relatório anual do desmatamento no Brasil 2023.
- Marengo, J. A. et al. (2021). Changes in climate and land use over the amazon region: Current and future variability and trends. *Frontiers in Earth Science*, 9:1–23.
- Nobre, C. et al. (2021). *Amazon Assessment Report 2021*. United Nations Sustainable Development Solutions Network, New York, USA.
- Penedo, G. et al. (2023). The refinedweb dataset for falcon llm: Outperforming curated corpora with web data only. *Advances in Neural Information Processing Systems*, 36:79155–79172.
- Yang, B. et al. (2025). Agrigpt: A large language model ecosystem for agriculture. *arXiv preprint arXiv:2508.08632*.
- Zhao, W. X. et al. (2023). A survey of large language models. *arXiv preprint arXiv:2303.18223*, 1(2):1–124.
- Zheng, L. et al. (2023). Judging llm-as-a-judge with mt-bench and chatbot arena. *Advances in neural information processing systems*, 36:46595–46623.